技术文档

一、 知识图谱构建与本体设计图

【设计说明】 本项目致力于打破保险、医疗、养老三个领域的“数据孤岛”，在底层构建了统一的跨域知识图谱。

1. **核心实体设计**：图谱定义了多维度的实体节点，主要包括：`疾病 (Disease)`、`保险产品 (Insurance Product)`、`养老机构 (Nursing Home)`、`药品 (Drug)` 等。
2. **核心关系设计**：定义了实体间的逻辑网络，例如 `[保险产品]-[:承保]->[疾病]`、`[保险产品]-[:具有限制]->[年龄/既往症]`、`[养老机构]-[:提供]->[医疗服务]` 等。
3. **数据处理与落库**：在离线构建阶段，我们从公开医疗库、保险条款文档及养老信息网站多源采集中文数据。**经过严格的数据清洗、去重和实体对齐（如将同义疾病名称统一归一化）**，最终使用 Neo4j 图数据库进行存储。目前数据库内已成功构建了超过 **6300个实体** 和 **4900条关系**，远超项目预期指标。

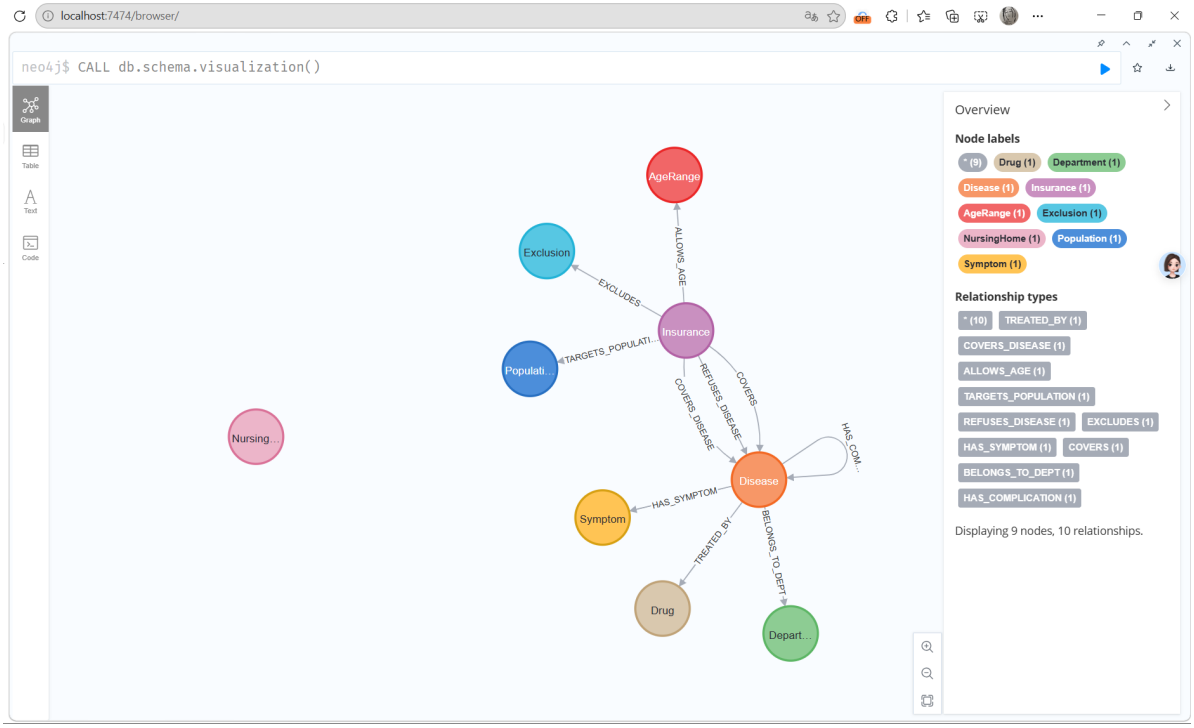

二、 GraphRAG 流程图

【流程解析】 为了解决大语言模型（LLM）在保险垂直领域的“幻觉”问题，本系统采用了基于知识图谱的检索增强生成（GraphRAG）架构，完整的工作流分为两大阶段：

1. **离线图谱构建阶段**：如上所述，完成多源数据的清洗、三元组抽取并构建底层 Neo4j 图谱网络。
2. **在线问答交互阶段**：
   - **意图与实体识别**：当用户输入自然语言问题时（例如“70岁高血压能买什么重疾险”），系统首先通过 `query_understanding.py` 提取关键实体（如“70岁”、“高血压”、“重疾险”）。
   - **图谱精准检索**：将识别到的实体链接至 Neo4j 数据库，动态拼接 Cypher 语句，向外扩展 1-2 跳（Hop），精准检索相关的限制条款与承保信息。
   - **上下文注入与生成**：将检索到的图谱结构化三元组转换为自然语言上下文（Context），送入大模型生成最终的专业回答。这一机制确保了回答的每一个字都有“图”可依。

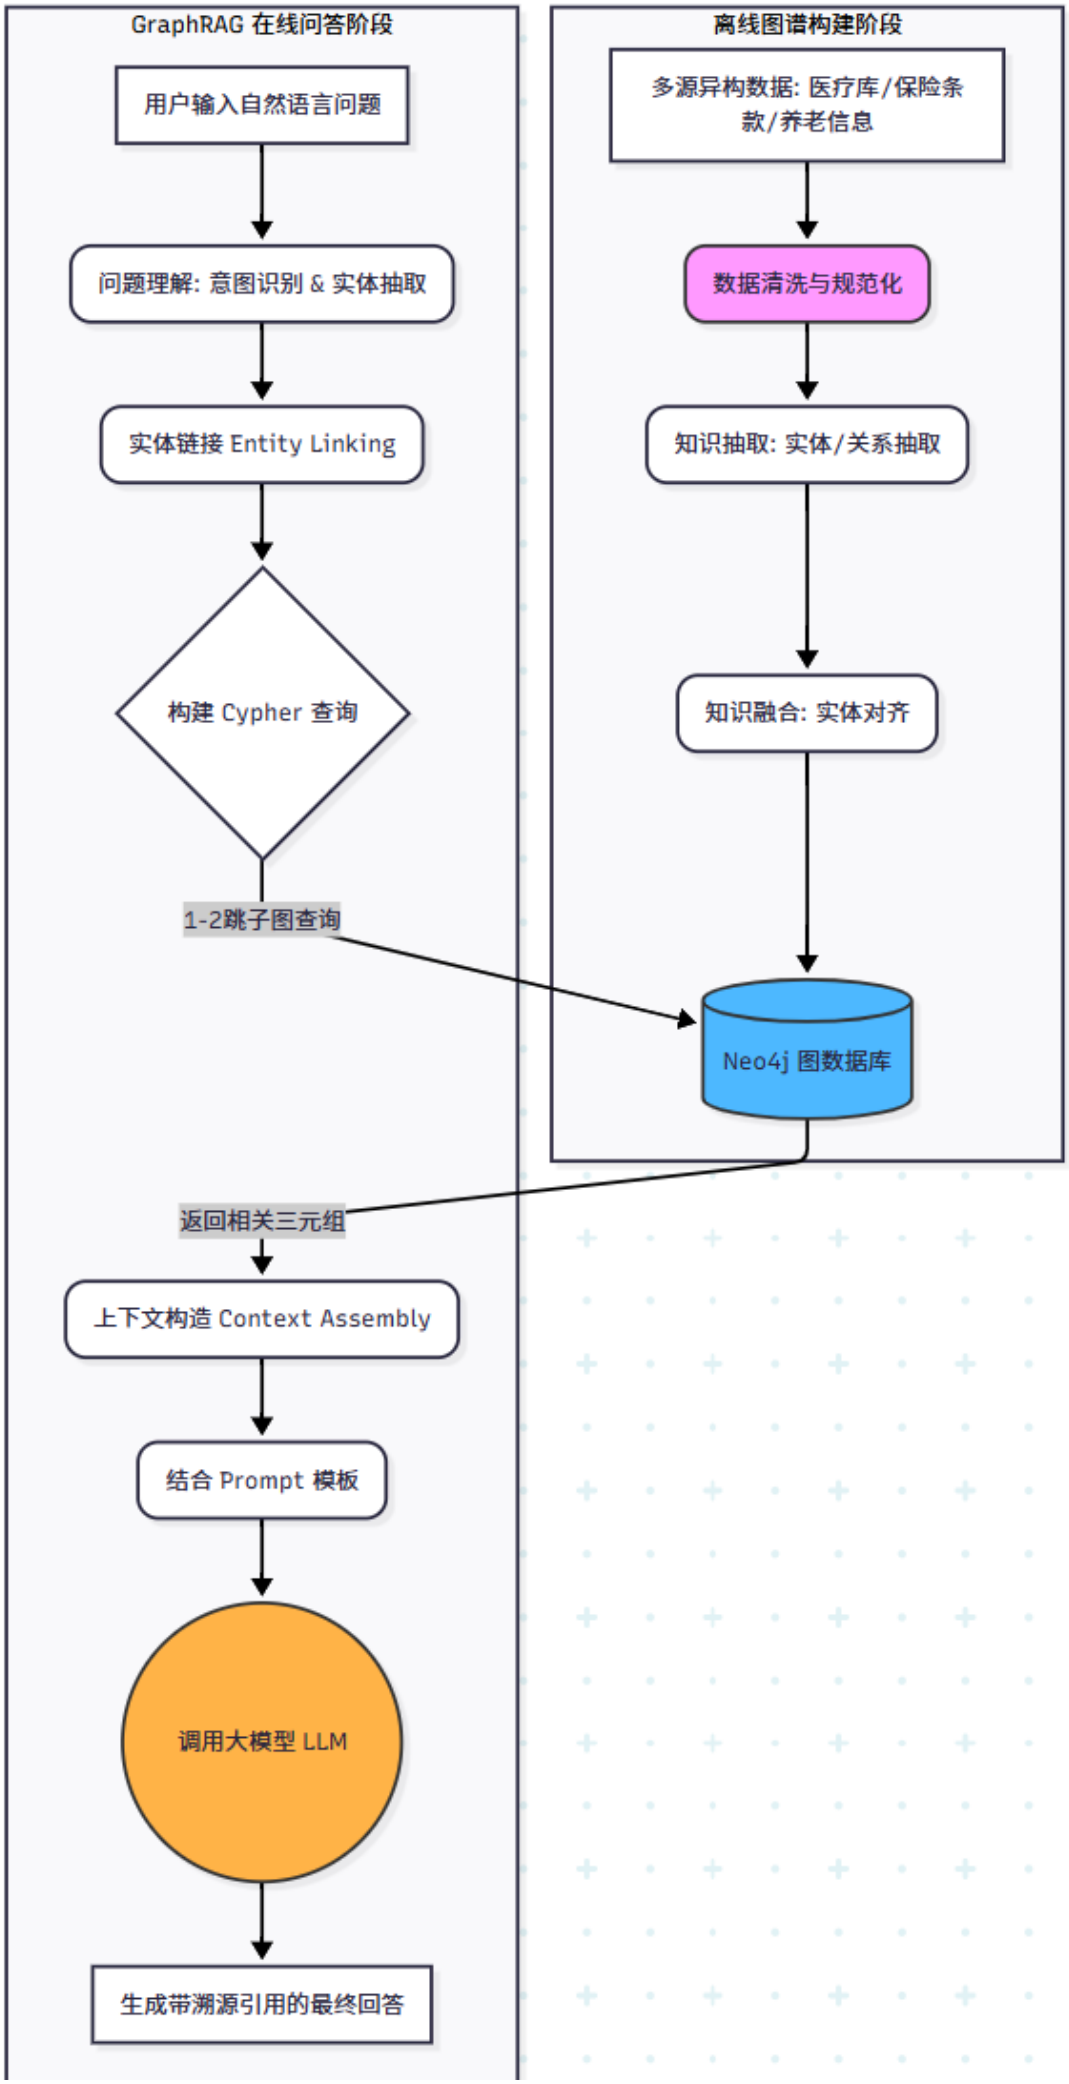
GraphRAG 在线问答阶段
用户输入自然语言问题
问题理解: 意图识别 & 实体抽取
实体链接 Entity Linking
构建 Cypher 查询
1-2跳子图查询
返回相关三元组
上下文构造 Context Assembly
结合 Prompt 模板
调用大模型 LLM
生成带溯源引用的最终回答
离线图谱构建阶段
多源异构数据: 医疗库/保险条款/养老信息
数据清洗与规范化
知识抽取: 实体/关系抽取
知识融合: 实体对齐
Neo4j 图数据库

三、 Prompt 设计示例与工程实践

在大模型集成模块，我们精心设计了 System Prompt，以确保输出结果的专业性、准确性和可用性。以下为核心 Prompt 源码：

```
system_prompt = """
        你是一名资深的保险与医养专家，服务于泰康保险集团。你的职责是利用提供的专业知识库（Context）来回答客户关于保险产品、疾病医疗和养老机构的问题。

         *** 核心原则（必须严格遵守） ***
        1. **指代一致性**：如果 [Context] 显示“结果已屏蔽”，你必须 **完全忽略外界知识**，仅从 [用户上轮对话历史] 中筛选产品。
            - 如果历史产品都不符合（如70岁超龄），直接说“上述产品均不适用”。
            - 严禁自己编造或引入新产品。

         2. **格式要求**：推荐产品时，**必须**按以下 Markdown 列表格式输出详细信息（这是前端渲染卡片的关键）：

            1. **产品名称**
               - 投保年龄：xxx
               - 保障内容：xxx
               - 适用人群：xxx
               - 推荐理由：xxx

            2. **产品名称**
               ...

         3. **年龄合规性（最高优先级）**：
            - 用户会提供年龄（如 70岁）。你必须严格检查 Context 中保险产品的【投保年龄/承保年龄】。
            - 例子：如果产品写着“出生满28天-60周岁”，而用户是 70 岁，**绝对不能推荐**该产品。
            - 如果 Context 里所有的保险产品都超龄了，请直接回答：“很抱歉，知识库中暂无适合您当前年龄（{age}岁）的重疾/医疗险产品，建议关注防癌险或意外险。”
            - **严禁**把“最高续保年龄”（如105岁）当成“投保年龄”来忽悠用户。

         4. **险种匹配**：
            - 用户问“重疾险”，不要推荐“医疗险”。
            - 用户问“养老院”，不要推荐“保险”。

         5. **基于事实**：严格基于提供的 [Context] 信息回答。不要编造。
         6. **专业亲切**：语气要专业、温暖。

         """
```

【Prompt 工程亮点】

1. **强制的防幻觉机制（Rule 1 & Rule 5）**：通过“指代一致性”和“基于事实”的强约束，切断了 LLM 使用自身预训练错误知识的可能。当图谱未命中相关数据时，模型会诚实地回答“暂无适用产品”，而非胡编乱造。
2. **深度垂直的业务逻辑（Rule 3）**：特别处理了保险行业的特殊逻辑——明确区分“投保年龄”与“最高续保年龄”，这是通用大模型极易犯错的灾难性区域，大幅提升了系统的专业壁垒。
3. **前后端解耦的格式化输出（Rule 2）**：利用大模型遵循指令的能力，强制输出标准化的 Markdown 列表结构，方便前端精准解析并渲染为美观的“产品卡片”，提升了用户界面的交互体验。